

Questions et réponses

Préparation de la soutenance — PFE BTK

Version vérifiée — ce qui a changé

Quatre corrections de chiffres (Q5, Q7, Q8), une question en double supprimée (Q3/Q4 étaient identiques), et le tableau des tests remplacé par celui du rapport — l'ancien citait une suppression de client que l'application ne sait pas faire. Récapitulatif en dernière page.

1 Architecture

1.1 Q1 — Est-ce que c'est du MVC ?

- Non : c'est une architecture **en couches** (N-tier), pas un MVC pur.
- Le MVC classique compte trois composants : Model, View, Controller.
- Ici il y a **quatre couches** : Présentation, Contrôle, Métier, Persistance.
- Dans un MVC pur, « Métier » et « Persistance » seraient fondus dans le Model.
- Le Model a donc été découpé en deux sous-couches, pour affiner la séparation.

Phrase à dire : *C'est une architecture en couches inspirée du MVC : Présentation = View, Contrôle = Controller, et le Model est affiné en Métier + Persistance.*

1.2 Q2 — Pourquoi pas un MVC pur, alors ?

- **Responsabilité unique** : le Model du MVC classique mélange règles métier et accès aux données.
- **Testabilité** : la couche Métier peut être testée seule, sans la vraie base Oracle.
- **Cohérence technique** : c'est le standard Jakarta EE — EJB pour le métier, JPA pour la persistance.
- **Évolutivité** : si la base change, ou si on ajoute une API REST, une seule couche est touchée.

Phrase à dire : *On n'a pas voulu un MVC pur pour éviter de surcharger le Model avec deux responsabilités différentes. En les séparant, on gagne en clarté, en testabilité et en flexibilité.*

1.3 Q3 — Différence entre méthode et méthodologie ?

- **Méthode** : une pratique concrète, un ensemble d'outils et de techniques appliqués — par exemple Scrum.
- **Méthodologie** : le cadre conceptuel qui guide le choix et l'enchaînement des méthodes.

Phrase à dire : *La méthodologie est le cadre théorique, la méthode est son application concrète — Scrum est une méthode issue de la méthodologie agile.*

Chiffre corrigé

Cette question figurait **deux fois** (Q3 et Q4), avec exactement la même réponse. Le doublon est supprimé, et la place est prise par une question qui tombe souvent : le choix de CRISP-DM.

1.4 Q4 — Pourquoi CRISP-DM et pas Scrum ?

- Le projet est **centré sur les données**, pas seulement sur la production de code.
- Scrum organise la fabrication logicielle mais ne dit rien de la compréhension des données ni de leur valorisation.
- CRISP-DM est la méthodologie de référence des projets décisionnels : compréhension métier, compréhension des données, préparation, modélisation, évaluation, déploiement.
- Ses six phases épousent le déroulement réel du projet, tout en gardant des pratiques agiles : itérations et validations régulières.

Phrase à dire : *Scrum organise la production logicielle ; CRISP-DM organise le travail sur la donnée. Mon projet allant de la donnée brute jusqu'à la décision, c'est CRISP-DM qui décrit le mieux mon déroulement.*

1.5 Q9 — Pourquoi Jakarta EE et pas Spring Boot, plus répandu ?

- **Standard robuste et éprouvé**, avec des spécifications stables : Servlets, EJB, JPA, CDI.
- **Portabilité** : aucune dépendance à un serveur précis.
- **Cohérence avec l'environnement bancaire**, où les serveurs d'applications de ce type sont déjà en place.
- **Séparation des responsabilités native** : EJB pour le métier, JPA pour la persistance — ce qui s'aligne exactement sur l'architecture en couches retenue.

Phrase à dire : *J'ai choisi Jakarta EE parce que c'est un standard robuste et portable, cohérent avec un environnement bancaire où la stabilité et la conformité aux standards priment sur la rapidité de développement.*

1.6 Q10 — Que voulez-vous dire par « workflows de validation » ?

- Certaines actions sensibles ne s'appliquent pas directement : elles passent par un circuit d'approbation.
- Exemple : le directeur commercial soumet une demande de création d'agence, l'administrateur la valide avant qu'elle prenne effet.
- Une modification de données personnelles va plus loin : **double validation** — le directeur approuve, puis l'administrateur applique.
- Cela évite qu'une seule personne modifie une donnée critique sans second contrôle.

Phrase à dire : *Un workflow de validation, c'est un circuit d'approbation : une action sensible est d'abord soumise, puis validée par un autre rôle avant d'être appliquée. Aucune donnée critique n'est modifiée par une seule personne.*

2 Segmentation et intelligence artificielle

2.1 Q5 — Pourquoi K-Means et pas un autre algorithme ?

- J'ai comparé quatre modèles : K-Means, agglomératif, GMM et DBSCAN.
- K-Means obtient le **meilleur score de silhouette : 0,604**, et le meilleur Calinski-Harabasz : 95,2.
- DBSCAN a un Davies-Bouldin plus favorable (0,393 contre 0,709), **mais il refuse de classer CENTRALE**, qu'il traite comme du bruit.
- Or un modèle de pilotage doit affecter **toutes** les agences à un segment : je retiens donc K-Means.

- Il est en outre simple, rapide, et permet de classer facilement une nouvelle agence.

Phrase à dire : *J'ai comparé quatre algorithmes. K-Means a la meilleure silhouette. DBSCAN a un meilleur Davies-Bouldin mais il rejette une agence comme bruit : je retiens le modèle qui classe toutes les agences, condition pour s'en servir en pilotage.*

Chiffre corrigé

La version d'origine annonçait « silhouette 0,736 et Davies-Bouldin 0,350, les meilleurs des quatre ». Ces valeurs venaient de l'ancienne exécution sur un jeu synthétique. Sur les données réelles : **0,604** et **0,709**, et le meilleur Davies-Bouldin est celui de DBSCAN. Le tableau du rapport porte les valeurs réelles.

Modèle	k	Silhouette	D.-Bouldin	Remarque
K-Means	3	0,604	0,709	retenu
DBSCAN	4	0,517	0,393	rejette CENTRALE comme bruit
GMM	3	0,446	0,770	
Agglomératif	3	0,417	0,841	

2.2 Q6 — Pourquoi k = 3 ?

- Deux méthodes combinées : la **méthode du coude** et le **score de silhouette**.
- La silhouette est en réalité maximale à k = 2 — mais k = 2 ne fait qu'isoler trivialement les entités sans activité.
- J'ai donc retenu la meilleure solution **à partir de k = 3**, la première qui soit exploitable pour le pilotage.

Phrase à dire : *k = 2 sépare trivialement les entités sans activité. J'ai retenu la meilleure solution à partir de k = 3, qui donne trois profils interprétables et utilisables par la direction.*

Chiffre corrigé

La version d'origine disait que « les deux méthodes convergent vers 3 ». C'est inexact et vérifiable dans la courbe de silhouette du rapport : le maximum est à k = 2 (0,681), k = 3 vient ensuite (0,604). Mieux vaut l'annoncer soi-même avec la justification métier.

2.3 Q7 — Pourquoi standardiser les données avant K-Means ?

- K-Means repose sur la **distance euclidienne**.
- Sans standardisation, une variable à grande échelle — la production de crédits, en centaines de millions — écraserait toutes les autres.
- `StandardScaler` centre et réduit : moyenne 0, écart-type 1, toutes les variables au même poids.
- J'ai en plus appliqué une **transformation logarithmique** aux montants et au portefeuille, dont la distribution est très asymétrique.

Phrase à dire : *K-Means utilise la distance euclidienne : sans standardiser les six variables, celles à grande échelle fausseraient les distances. J'ai aussi passé les montants au logarithme, parce que leur distribution est très asymétrique.*

Chiffre corrigé

La version d'origine parlait des « 7 variables ». La segmentation en utilise **six** : effectif, gestionnaires, clients, comptes, crédits, épargne. Le taux de présence n'est pas retenu — il mesure l'assiduité, pas la taille ni l'activité commerciale.

2.4 Q8 — C'est quoi le score de silhouette ?

- Une mesure de qualité du regroupement, comprise entre -1 et 1 .
- Proche de 1 : les points sont serrés dans leur groupe et bien séparés des autres.
- Ici : **0,604**, ce qui indique des groupes nettement distincts.

Phrase à dire : *Le score de silhouette évalue si un point est proche de son propre groupe et loin des autres. Notre 0,604 indique des groupes bien séparés.*

2.5 Q16 — Comment avez-vous réalisé la segmentation ?

J'ai utilisé le datamart produit par la chaîne ETL : **49 entités** du réseau et **six indicateurs**. Le siège est écarté de l'analyse — 540 employés, c'est une structure centrale, pas une agence — ce qui laisse **48 entités**. J'ai appliqué une transformation logarithmique aux montants, standardisé les variables, puis retenu trois groupes avec la méthode du coude et la silhouette.

2.6 Q17 — Pourquoi avoir standardisé les données ?

Parce que les variables n'ont pas les mêmes échelles. La standardisation les rend comparables et évite qu'une variable à grandes valeurs domine les autres dans le calcul des distances.

2.7 Q18 — Pourquoi avoir choisi K-Means ?

J'ai comparé quatre modèles. K-Means obtient le meilleur score de silhouette, et il est le plus pertinent pour le pilotage : chaque agence est affectée à un segment, et une nouvelle agence peut être classée immédiatement.

2.8 Q19 — Quels modèles avez-vous comparés ?

K-Means, l'agglomératif, GMM et DBSCAN.

Citer les quatre suffit, à condition de savoir justifier le choix de K-Means (voir Q5).

3 Décisionnel, KPI et Power BI**3.1 Q11 — Pourquoi ces KPI, et sous quels critères ?**

Les KPI ont été choisis en fonction des besoins métier identifiés et des données réellement disponibles dans les sources de la banque. L'objectif était de couvrir les principaux axes de pilotage du réseau : les ressources humaines, l'activité commerciale, la clientèle et l'assiduité. J'ai donc retenu des indicateurs qui permettent à la direction de mesurer la taille et l'activité des agences, leur performance commerciale et la présence des employés.

3.2 Q15 — Quels sont vos KPI ?

Le nombre de clients, la production de crédits, le total des comptes ouverts, la collecte d'épargne, le taux de présence, la répartition des rôles et la segmentation des agences. Ils évaluent à la fois la performance commerciale des agences, leur capacité à développer leur portefeuille, et leur organisation interne.

Si on demande un seul exemple : *nombre de clients* mesure la taille du portefeuille de l'agence ; *taux de présence* mesure l'assiduité des équipes.

3.3 Q12 — Comment fonctionne votre chaîne ETL ?

Elle est implémentée en Python avec pandas, et exécutée dans un notebook connecté à la base Oracle. Elle enchaîne cinq étapes : collecte des cinq tables sources, nettoyage, transformation, intégration sur la clé SK_AGENCE, et contrôle de qualité. Le contrôle final vérifie l'absence de valeur manquante, de valeur négative et d'agence en double — et **interrompt le chargement** si l'un d'eux échoue.

3.4 Q13 — C'est quoi une mesure DAX ?

C'est un calcul défini dans Power BI qui produit dynamiquement un indicateur à partir des données du modèle. Il est évalué **au moment de l'affichage**, dans le contexte des filtres actifs.

3.5 Q14 — Donnez-moi un exemple de mesure.

- **Nb Employés** : compte le nombre distinct d'employés à partir de SK_UTILISATEUR.
- **Nb Clients** : compte le nombre distinct de clients à partir de SK_CLIENT.
- **Taux Présence** : rapport entre les pointages « présent » ou « retard » et le total des pointages.

À savoir par cœur

Mesure ou colonne calculée ? C'est la relance la plus fréquente après une question DAX. Une **colonne calculée** est évaluée à l'actualisation et stockée : elle sert à *filtrer ou grouper*. Une **mesure** est évaluée à l'affichage, dans le contexte des filtres : elle sert à *agréger*. Dans mon rapport, Rôle est une colonne calculée, Taux Présence une mesure.

Les données du volet IA proviennent du **datamart produit par la chaîne ETL**, et non directement de la base opérationnelle.

4 Les tests réalisés

Chiffre corrigé

Le tableau d'origine listait dix scénarios dont deux ne correspondent pas à l'application : « Suppression d'un client » — l'application ne sait pas supprimer un client, il n'existe aucune opération de suppression dans le service correspondant — et « Modification d'un employé », qui ne se fait pas directement mais passe par le circuit de demande à double validation. Le tableau ci-dessous est celui du **rapport remis au jury** : c'est celui qu'il faut citer, pour ne pas se contredire.

#	Module	Scénario testé	Résultat
1	Authentification	Connexion avec des identifiants valides puis invalides.	Conforme
2	Rôles	Accès à une fonction réservée à l'ADMIN par un USER.	Conforme
3	Agences	Création, modification et suppression d'une agence.	Conforme
4	Employés	Ajout d'un employé et rattachement à une agence.	Conforme
5	Clients	Affectation d'un client à un gestionnaire.	Conforme
6	Objectifs	Consultation de la production par agence et période.	Conforme
7	Pointage	Pointage au-delà de 9 h (détermination du statut).	Conforme (RETARD)
8	Demandes	Validation puis refus d'une demande, avec journalisation.	Conforme
9	ETL	Exécution du pipeline et production du datamart.	Conforme
10	Décisionnel	Filtrage par district dans le rapport Power BI.	Conforme

Si on vous demande quels tests vous avez faits, en citer deux ou trois et décrire le résultat obtenu. Les plus faciles à raconter : le pointage après 9 h qui bascule en RETARD, et l'accès refusé à un USER sur une page réservée à l'ADMIN.

Récapitulatif des corrections

Point	Version d'origine	Version vérifiée
Q3 / Q4	question posée deux fois, réponse identique	doublon supprimé, remplacé par le choix de CRISP-DM
Q5	silhouette 0,736 , Davies-Bouldin 0,350 , « les meilleurs »	silhouette 0,604 , Davies-Bouldin 0,709 ; DBSCAN a un meilleur Davies-Bouldin mais rejette une agence
Q6	« les deux méthodes convergent vers 3 »	la silhouette est maximale à $k = 2$; $k = 3$ est le meilleur choix exploitable
Q7	« les 7 variables »	six variables ; le taux de présence n'est pas retenu
Q8	« 0,736 = bon résultat »	0,604
Tests	« Suppression d'un client », « Modification d'un employé »	remplacés par les dix scénarios du rapport

Inchangé et vérifié : Q1, Q2, Q9, Q10, Q11, Q12, Q13, Q14, Q15, Q16 (49 entités et 6 indicateurs : déjà juste), Q17, Q18, Q19.